DevOpsPilot 技术方案书

CodeArts 2026 模型应用赛

材料日期 2026 年 10 月 7 日

源码基线 7076541e445a9f2da365b52fce74cf6df3c4ff17

1 作品概述

作品名称 DevOpsPilot；参赛团队 CodeArts；赛道 2026 模型应用赛。作品面向研发维护人员，将真实 Issue 接入、模型执行、代码变更、独立审查、PR、CI 与交付证据连接到一个本机 Web 工作台。

目前可展示真实项目查询、持久化流水线和一次受控 GitHub fixture 交付。现有实现由本地源码、41 项离线检查、24 个题库预置验证，以及实际 PR 和 CI 支持。当前版本为提交材料基线，不宣称已达到生产级自治交付或完成所有 PRD 签收。

目标用户为有代码仓库与 CI 基础设施的研发团队、DevOps 工程师和开源维护者。首先验证小规模、可回滚、路径可约束的维护任务；政务与金融行业规则包作为工程示例，不能替代法规认证。

2 用户场景与能力设计

典型路径为操作员接入项目并设置可信测试命令与路径边界，在需求中心同步真实 Issue，显式选择任务与意图，提交后台执行，观察 VOD、Issue、Coding、QA、SRE 五阶段，检查代码、审查、CI 链接并下载证据。阶段卡片是交付状态视图，不代表五个常驻独立智能体。

项目配置与 Issue 内容分离。任务正文不能覆盖可信测试命令、允许修改路径、禁止路径和 required checks。后台任务持久化，重复启动去重；已有交付使用 resume 继续，服务重启留下的作业显示 interrupted。

一次性预约由本机服务调度，可取消；Chat 调用真实 MoMA 并展示实际 usage。知识库读取仓库 Markdown，技能页读取行业 Pack，题库页读取真实 case.json。未配置的 IM 和未接入的 CNB Live 执行明确标为未接入。

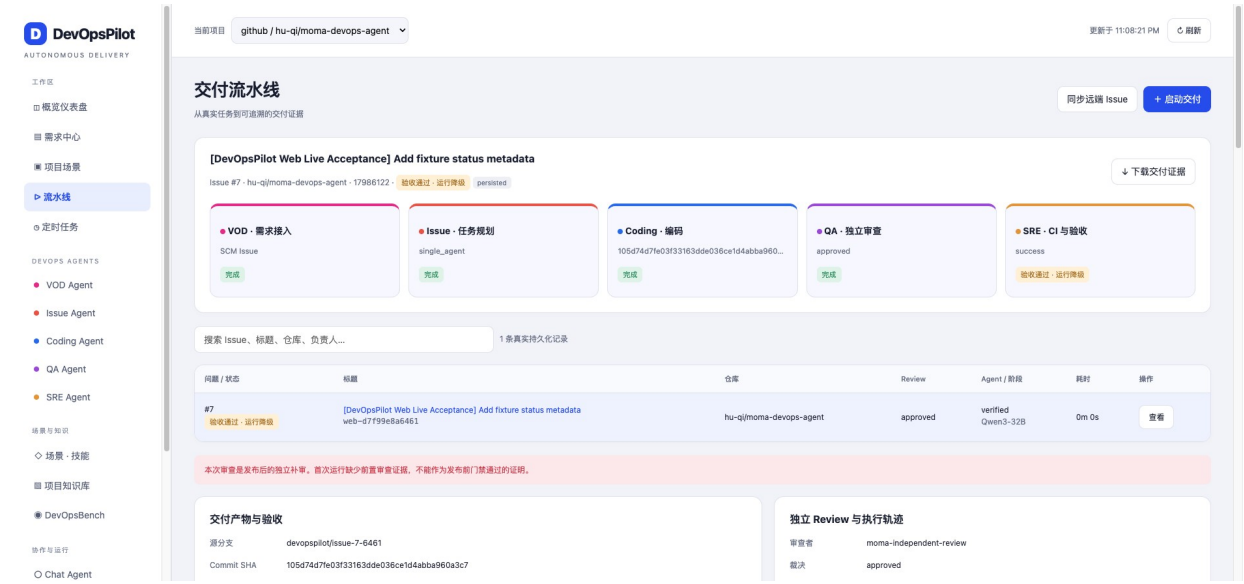


图 1 真实 Web 持久化流水线 当前运行明确标注降级

3 系统架构与移动云模型分工

Web 和 CLI 是接入层。ConsoleService 读取 canonical SQLite 交付 payload，并使用旁路 console 数据库保存项目、作业、预约和问答。控制面负责意图、计划、预算、状态与恢复；执行适配器承接 OpenJiuwen 运行；SCM 和 CI 适配器读取或写入真实平台；验证器决定 verified、rejected、pending 与 degraded。

MoMA 使用统一 API 入口。当前配置：deepseek-v4.1-flash 用于快速角色及独立 Review，GLM-5.3 用于推理与 Judge，Qwen3-32B 用于 Coding 及 Evolution。材料不包含 API 密钥，不假设配置模型即等于每个事件实际调用模型；真实模型调用以轨迹与 usage 为准。

OpenJiuwen 负责智能体与工具运行，MoMA 提供模型推理，DevOpsPilot 控制面负责可信配置、持久化与交付判定。现有 Runtime 版本由 requirements-runtime.txt 固定；框架运行异常与业务任务成功分别记录。GitHub 和 AtomGit 有 Live 装配，平台 CI 能力差异保留，不把 AtomGit 描述为原生 Actions。

4 Prompt 策略 工具设计与审查门禁

执行上下文包含目标、任务来源、仓库状态、允许路径、测试命令与预算。提示明确要求读取代码、做最小修改、执行测试、停止无关任务板循环；但提示并非权限隔离。路径验证与执行后检查在宿主侧执行，工作目录不能被视为安全沙箱。

独立 Reviewer 为只读模型调用，收到实际最终 diff 与独立测试结果。system prompt 把 diff 和测试文本视为不可信数据，要求返回结构化 approved/rejected、summary、findings；宿主计算 diff 摘要并生成审查时间。严格 Live 启动强制 require_review，缺失、拒绝、格式错误或 diff 不匹配阻断提交。

SCM 发布通过持久化状态与幂等意图控制；CI 验证需关联真实提交与 required checks。预算在失败执行中消耗，超限升级人工。工具超时与取消清理进程组。当前控制台仅面向可信本机操作员，未提供多用户认证、RBAC 或公网服务。

5 真实交付结果与证据边界

2026 年 10 月 7 日经 Web 启动 GitHub Issue #7：Add fixture status metadata。操作范围仅为 e2e/fixtures/github_delivery/app.py 与 test_app.py，保留原 status 行为并增加 status_metadata 和断言。真实 PR #8 保持未合并，交付 commit 为 105d74d7fe03f33163dde036ce1d4abba960a3c7。

GitHub Actions run 37601566835 在上述提交上成功；独立 fixture 测试退出码 0。审查模型 deepseek-v4.1-flash 返回 approved，diff 摘要 ceebbaf775d5cdab6fb0946437d962569f35d40bc26c0e92e27ab3ab5cedc26d。

该首次运行产生有效代码后，AgentTeam 未干净结束而达到超时边界。原执行遗漏前置审查，随后进行了真实发布后补审。最终状态 verified_degraded，task_success=true、runtime_clean_completion=false。严格 Live 门禁现已修复，完整修复后 Live 重跑尚未完成；不能将补审作为原发布前审查成功证据。

PR 链接 https://github.com/hu-qi/moma-devops-agent/pull/8 。CI 链接 https://github.com/hu-qi/moma-devops-agent/actions/runs/37601566835 。原始摘要位于 evidence/web-console-delivery.json。

6 效果评估与可复算方法

当前完整离线检查为 41 项，最新已留存运行结果 41 通过、0 失败、19.65 秒。这是受控环境组件回归结果，不是 41 个真实业务任务的成功率。当前 24 个 DevOpsBench 案例分为 coding、code-review、ci-debug 各 8 例，其中每类 2 例 holdout，共 6 例。

本次运行 validate-fixtures 得到 24 通过、0 失败。该命令验证初始缺陷与 oracle 契约有效，不调用模型，也不证明 Agent 修复成功。完整 A0–A3 同题同预算重复实验没有完整原始结果可用于正式比较，因此不报告成功率提升、降本百分比或统计显著性。

后续冻结 RC、模型、题库和预算后，按 24 例×4 策略×3 次生成至少 288 条原始记录，保留失败样本，按类别与 holdout 分组重算成功率、耗时、tokens、人工介入与运行健康。价格未经核实记 unestimated。方法与当前事实报告见 EVALUATION_REPORT.md。

7 商业价值与产品 RoadMap

商业价值假设：团队可减少在 Issue、代码、PR、CI 与日志之间的切换，保留审查与恢复证据，帮助人工判断是否接受交付。潜在客户为已有代码托管与 CI 的企业研发部门；适合先从内部维护任务试点。当前没有正式付费客户、用户访谈结论或 ROI 实测，不把市场假设写成收益成果。

拟议商业模式为私有化部署与支持、团队级订阅及行业 Pack 服务。定价需通过试点确认调用成本、交付成功率、人工复核时间和部署成本后制定。MoMA 价值在于统一接入与多模型配置；本作品尚未独立测量 MoMA 相对其他平台的价格或时延优势。

RoadMap 按验收推进：提交基线为材料与证据可携带；稳定版修复 Runtime 终止并完成前置 Review Live 重跑；V1 完成 CI 红转绿、行业 Gate 与中断恢复签收；评测版完成 288 条原始记录和受控进化正反例；企业试点再补认证、隔离、Webhook 运营与成本治理。具体依赖、角色与验收见 ROADMAP.md。

8 部署复现与提交说明

源码包固定到 7076541e445a9f2da365b52fce74cf6df3c4ff17，不包含.env、数据库、虚拟环境、工作目录或私密运行日志。Python 3.11 为建议运行环境；安装核心、测试与固定 Runtime 依赖后执行离线检查。无凭据路径只验证离线行为，Live 需要操作员在本地提供 MoMA 与 SCM 凭据。

启动命令为.venv/bin/python scripts/serve_dashboard.py --port 8080；浏览器访问 http://127.0.0.1:8080。联网演示读取真实缓存与 API，断网使用随包交付的真实证据 HTML 回放。视频采用真实页面截图证据回放，含合成中文旁白和字幕，不冒充连续 Live 操作录屏。

官方页面已确认模型应用赛使用附件 2 统一 PPT 模板；五项内容已映射到本套材料。作品按团队名称-队长姓名-队长手机号-作品名称命名目录后压缩，由队长上传。团队名称 CodeArts 已在登录页面读取；完整队长姓名与手机由人类最后核对，公开目录暂不包含个人信息。

官方上传页本次显示剩余约 7 天 15 小时，未展示绝对截止时间、文件大小或视频时长上限。提交前需核对实时倒计时与系统限制；本包不臆造这些限制。成员审核、原创性声明、账户身份及最终提交由团队确认。